PROJET RÉALISÉ PAR

L'ÉQUIPE EFFICIENCY DU GROUPE DE TD2

RAPPORT DE GROUPE DES UE BASES DE DONNÉES + SCIENCES DES DONNÉES 2

Hounsa Tylden, Oussaid El Amri Noha, Sylla Mary-Yohana, Tall Aissatou



Département MIASHS, UFR 6 Informatique, Mathématique et Statistique
Université de Montpellier Paul-Valéry

3 Mai 2026

Soumis comme contribution partielle
pour le cours Science des données 2 et Bases de données

Déclaration de non plagiat

Nous déclarons que ce rapport est le fruit de notre seul travail, à part lorsque cela est indiqué explicitement.

Nous acceptons que la personne évaluant ce rapport puisse, pour les besoins de cette évaluation :

- la reproduire et en fournir une copie à un autre membre de l'université ; et/ou,
- en communiquer une copie à un service en ligne de détection de plagiat (qui pourra en retenir une copie pour les besoins d'évaluation future).

Nous certifions que nous avons lu et compris les règles ci-dessus.

En signant cette déclaration, nous acceptons ce qui précède.

Signature : Hounsa Tylden Date : 01/04/2026

Signature : Oussaid El Amri Noha Date : 01/04/2026

Signature : Sylla Mary-Yohana Date : 01/04/2026

Signature : Tall Aissatou Date : 01/04/2026

3 mai 2026

Remerciements

Nos plus sincères remerciements vont à notre encadrant pédagogique pour les conseils avisés sur notre travail.

Nous remercions également Kaggle et l'Organisation Mondiale de la Santé pour la mise à disposition publique des jeux de données utilisés dans ce projet.

3 mai 2026

Résumé

La pollution atmosphérique constitue l'une des principales causes de mortalité évitable à l'échelle mondiale. Ce rapport croise des données environnementales issues de Kaggle (23 464 villes, indice AQI et concentration en PM2.5) avec des statistiques sanitaires de l'OMS (taux de mortalité par maladies liées à la pollution, 183 pays, année 2016), afin d'examiner la corrélation entre qualité de l'air urbaine et mortalité nationale. Après constitution d'une base de données relationnelle sous MySQL (tables PAYS, VILLE et SANTE), une démarche en trois étapes révèle l'importance du choix de l'indicateur de mortalité : l'absence de corrélation sur les taux bruts ($r = 0{,}035$) s'explique par un biais démographique, corrigé par l'utilisation des taux standardisés selon l'âge fournis par l'OMS. Après identification et exclusion d'une valeur aberrante, une corrélation positive modérée et statistiquement significative est établie entre le niveau moyen de PM2.5 par pays et le taux de mortalité standardisé ($r = 0{,}28$, $p < 0{,}001$). Un modèle de régression linéaire simple quantifie cet effet, et une segmentation par K-means identifie trois profils de pays distincts. Ces résultats soulignent l'importance du choix des indicateurs dans ce type d'étude et plaident pour le développement de données de morbidité comparables à l'échelle internationale.

Table des matières

Chapitre 1 Introduction 1
- 1.1 Présentation du contexte et problématique . . . 1
- 1.2 Responsabilités et composition de l'équipe . . . 1
- 1.3 Quelques détails techniques . . . 2

Chapitre 2 Base de données 3
- 2.1 Provenance des données . . . 3
- 2.2 Descriptif des tables . . . 3
- 2.3 Modèles MCD et MOD . . . 5
- 2.4 Import des données . . . 6
  - 2.4.1 Création de la table de référence : PAYS . . . 6
  - 2.4.2 Structuration de la table VILLE . . . 6
  - 2.4.3 Structuration de la table SANTE . . . 7
  - 2.4.4 Importation sous PHPMyAdmin . . . 7
- 2.5 Requêtes réalisées . . . 7
  - 2.5.1 Requête 1 : Quels sont les dix pays présentant la plus forte concentration moyenne en PM2.5 ? . . . 7
  - 2.5.2 Requête 2 : Quels pays présentent un AQI moyen supérieur à la moyenne mondiale ? . . . 8
  - 2.5.3 Requête 3 : Comment la mortalité évolue-t-elle selon la catégorie d'AQI ? . . . 9
  - 2.5.4 Requête 4 : Les pays avec un AQI « Unhealthy » ont-ils un taux de mortalité supérieur à ceux classés « Good » ? . . . 10
  - 2.5.5 Requête 5 : Impact différencié par sexe sur les Accidents Vasculaires Cérébraux (AVC) . . . 11
  - 2.5.6 Requête 6 : Comparaison pollution PM2.5 et mortalité par bronchopneumopathie chronique (BPCO) — top 15 des pays les plus pollués . . . 11

Chapitre 3 Matériel et Méthodes 13
- 3.1 Logiciels et environnement technique . . . 13
- 3.2 Modélisation statistique . . . 13

Chapitre 4 Analyse Exploratoire des Données 14
- 4.1 Nature des variables . . . 14
- 4.2 Visualisations univariées . . . 15
  - 4.2.1 Distribution du PM2.5 . . . 15
  - 4.2.2 Résumé numérique du PM2.5 . . . 15
  - 4.2.3 Répartition des catégories AQI . . . 16

4.3 Analyse bivariée : Pollution vs Mortalité 16

Chapitre 5 Inférence statistique et modélisation 18
5.1 Test du coefficient de corrélation de Pearson 18
5.1.1 Étape 1 - Analyse sur les taux de mortalité bruts 18
5.1.2 Étape 2 - Correction du biais démographique par standardisation 19
5.1.3 Étape 3 - Identification et traitement de la valeur aberrante 19
5.2 Régression linéaire simple 21
5.3 Analyse de variance (ANOVA) par catégorie AQI 22
5.4 Segmentation par K-means 23

Chapitre 6 Discussion 25
6.1 Synthèse des résultats 25
6.2 Limites de l'étude 25

Chapitre 7 Conclusion et perspectives 27
7.1 Conclusions principales 27
7.2 Perspectives à court terme 27
7.3 Perspectives à long terme 27
7.4 Difficultés rencontrées 27

Bibliographie 28

Annexes 29

Chapitre 1

Introduction

1.1 Présentation du contexte et problématique

La dégradation de la qualité de l'air est aujourd'hui reconnue comme l'une des menaces les plus graves pour la santé publique mondiale. Selon les rapports de l'Organisation Mondiale de la Santé (OMS), l'exposition prolongée aux polluants atmosphériques, et plus particulièrement aux particules fines (PM2.5), est directement associée à l'augmentation des pathologies respiratoires chroniques et des décès prématurés. Les particules PM2, dont le diamètre aérodynamique est inférieur à 2,5 micromètres, sont particulièrement dangereuses car elles pénètrent profondément dans les alvéoles pulmonaires et peuvent atteindre la circulation sanguine, provoquant des effets systémiques bien au-delà du seul appareil respiratoire.

L'enjeu de ce projet est de croiser des mesures environnementales urbaines avec des indicateurs de mortalité pour vérifier la réalité de cet impact à l'échelle globale. Notre recherche s'articule autour de la question suivante :

Existe-t-il une corrélation significative entre les niveaux de pollution urbaine (AQI et PM2.5) et les taux de mortalité par maladies respiratoires à l'échelle mondiale ?

Cette question est cruciale car elle permet d'évaluer l'efficacité des politiques environnementales actuelles. Si une corrélation forte est établie, cela justifierait des mesures plus restrictives sur les émissions polluantes dans les zones urbaines denses, afin de réduire la pression sur les systèmes de santé publique. Les résultats de cette étude pourront également servir d'appui scientifique à des organisations souhaitant prioriser leurs interventions géographiques.

1.2 Responsabilités et composition de l'équipe

— **Tylden Hounsa** : Étudiant n°22412555, Responsable du rapport et des analyses SQL (Rédacteur principal du .Rmd).

— **Noha Oussaid El Amri** : Étudiante n°22413984, Responsable de la collecte et du nettoyage des données (*Data Cleaning*).

— **Mary-Yohana Sylla** : Étudiante n°22414031, Responsable de la modélisation de la base de données (MCD/MOD).

— **Aissatou Tall** : Étudiante n°22414034, Responsable des visualisations graphiques et de l'analyse exploratoire.

1.3 Quelques détails techniques

Pour la réalisation de ce rapport, nous utilisons **R Markdown** via **RStudio**, ce qui permet d'intégrer directement nos scripts d'analyse au sein du document et d'en assurer la reproductibilité. La qualité rédactionnelle est vérifiée via l'outil LanguageTool (https://languagetool.org/fr). Les schémas relationnels sont conçus avec **Mocodo** (https://www.mocodo.net/) pour le MCD, et avec le designer de **PHPMyAdmin** pour le MOD.

Chapitre 2

Base de données

2.1 Provenance des données

Nous avons sélectionné deux jeux de données provenant de sources officielles et distinctes pour répondre à notre problématique :

Données de Pollution (Source Environnementale) :
— Lien : Kaggle – Global Air Pollution Dataset (basé sur OpenAQ).
— Description : Ce fichier recense les indices de qualité de l'air (AQI) et les concentrations de plusieurs polluants pour plus de 23 000 villes à travers le monde. Nous l'avons retenu pour sa granularité urbaine et son étendue géographique internationale.
— Format : .csv | Taille : 1 593 ko | Dimensions : 23 464 lignes × 12 colonnes.

Données de Santé (Source Médicale) :
— Lien : OMS – Air Pollution Death Rate.
— Description : Statistiques de mortalité attribuable à la pollution atmosphérique, publiées par l'OMS pour l'année 2016 et couvrant 183 pays. Nous avons filtré les données pour ne conserver que les indicateurs relatifs aux maladies respiratoires et cardiovasculaires directement liées à la pollution.
— Format : .csv | Taille : 1 036 ko | Dimensions : 6 589 lignes × 6 colonnes.

Population étudiée : L'unité statistique retenue est le **pays**. Bien que les données de pollution soient mesurées à l'échelle de la ville, nous les agrégeons par pays, via une moyenne du PM2.5, pour permettre la jointure avec les données de l'OMS, disponibles uniquement à l'échelle nationale. Cette agrégation introduit cependant une perte de granularité explicitée dans la partie Discussion.

2.2 Descriptif des tables

Après nettoyage et structuration des données, nous avons constitué trois tables : PAYS, VILLE et SANTE. Leurs caractéristiques sont détaillées ci-dessous.

Nom colonne	Type	Signification	Caractéristique
id_pays	INT NOT NULL	Identifiant numérique unique	Clé primaire, séquentiel 1–192
nom_pays	VARCHAR(100) NOT NULL	Nom du pays (en anglais)	192 valeurs uniques

Table 2.1: Table PAYS (2 colonnes × 192 lignes)

Nom colonne	Type	Signification	Caractéristique
id_stat	INT NOT NULL	Identifiant de la ligne	Clé primaire
indicateur	VARCHAR(25)	Type de taux de mortalité	`attributable`, `attributable_age_std`
maladie	VARCHAR(150)	Cause de décès	Total, Lower respiratory infections, Trachea bronchus lung cancers, Ischaemic heart disease, Stroke, Chronic obstructive pulmonary disease
valeur_taux	FLOAT	Taux de mortalité pour 100 000 hab.	1,00 – 99,91
periode	INT	Année de relevé	2016
sexe	VARCHAR(20)	Sexe concerné	Female, Male, Both sexes
id_pays	INT NOT NULL	Référence au pays	Clé étrangère → PAYS

TABLE 2.2: Table SANTE (7 colonnes × 6 588 lignes)

Nom colonne	Type	Signification	Caractéristique
id_ville	INT NOT NULL	Identifiant de la ville	Clé primaire
nom_ville	VARCHAR(150) NOT NULL	Nom de la ville	≈23 000 villes distinctes
aqi_value	INT	Indice de Qualité de l'Air	6 – 500
pm25_value	INT	Concentration en PM2.5 (μg/m^3)	0 – 500
aqi_category	VARCHAR(50)	Catégorie de qualité de l'air	Good, Moderate, Unhealthy_for_Sensitive_Groups, Unhealthy, Very_Unhealthy, Hazardous
id_pays	INT NOT NULL	Référence au pays	Clé étrangère → PAYS

TABLE 2.3: Table VILLE (6 colonnes × 23 035 lignes)

2.3 Modèles MCD et MOD

Le Modèle Conceptuel de Données (MCD) a été réalisé avec Mocodo. Il représente les trois entités PAYS, VILLE et SANTE, reliées par des associations de cardinalités (1,n) : un pays peut être associé à plusieurs villes et à plusieurs entrées sanitaires.

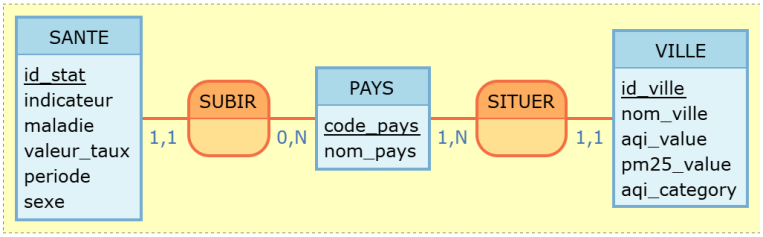


FIGURE 2.1: MCD réalisé avec Mocodo.

Le Modèle Organisationnel de Données (MOD) a été généré via le designer de PHPMyAdmin. Il formalise les types de données et les contraintes de clés étrangères entre les tables.

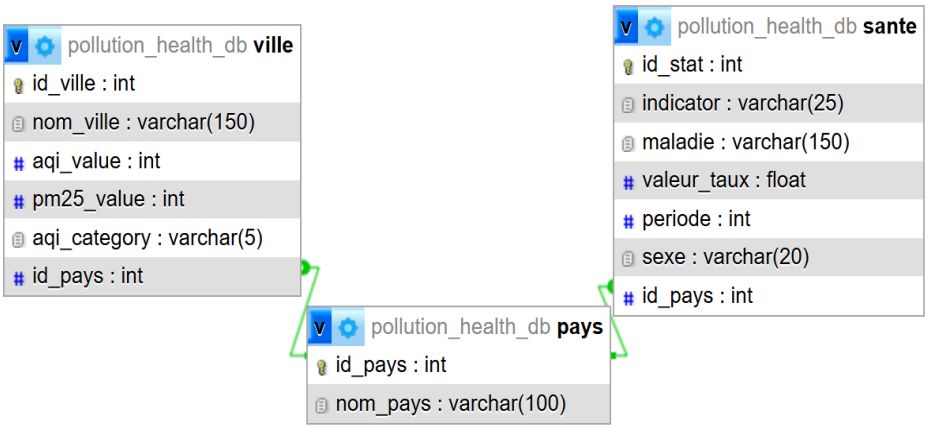


FIGURE 2.2: MOD généré via le designer de PHPMyAdmin.

2.4 Import des données

Afin de garantir l'intégrité référentielle et la qualité des analyses futures, un processus rigoureux de nettoyage et de structuration a été mené à l'aide du logiciel **LibreOffice Calc**. Ce traitement a permis de passer de deux fichiers CSV « plats » à une structure relationnelle conforme à notre MCD.

2.4.1 Création de la table de référence : PAYS

La table `PAYS` sert de pivot central entre les deux sources de données. Son élaboration a suivi les étapes suivantes :

- **Extraction et fusion :** Les colonnes `Country` (base pollution) et `Location` (base santé) ont été consolidées dans une feuille unique afin d'obtenir la liste complète des pays présents dans les deux sources.
- **Dédoublonnage :** La fonction native **"Supprimer les doublons"** a permis d'obtenir une liste de nations uniques. Les noms étant uniformément en anglais dans les deux sources, aucune erreur de traduction n'a été relevée. Quelques doublons mineurs (ex. : « Côte d'Ivoire » présent deux fois sous des encodages différents) ont été corrigés manuellement.
- **Indexation :** Les pays ont été triés par ordre alphabétique, puis un identifiant unique a été attribué. La colonne a été renommée `id_pays` et constitue la clé primaire de la table.

2.4.2 Structuration de la table VILLE

Pour la table `VILLE`, une sélection et un enrichissement des données ont été opérés :

- **Sélection d'attributs :** Parmi les 12 colonnes du fichier source, seules 4 ont été conservées et renommées : `nom_ville`, `aqi_value`, `pm25_value` et `aqi_category`. Les colonnes relatives aux autres polluants (NO2, CO, O3) ont été écartées, car notre problématique se concentre sur les PM2.5.
- **Jointure logique :** La fonction `RECHERCHEV` a permis d'attribuer à chaque ville son identifiant `id_pays` en recherchant le nom du pays associé dans la table `PAYS`.

— **Nettoyage :** La colonne textuelle `Country` a ensuite été supprimée. Les lignes présentant des données manquantes ou des villes sans correspondance nationale ont été éliminées pour ne pas biaiser les traitements statistiques.

2.4.3 Structuration de la table SANTE

Le traitement de la base de l'OMS a nécessité un filtrage et un remapping des champs :

— **Mapping des champs :** Les colonnes `Indicator`, `Dim2`, `Period` et `Dim1` ont été renommées respectivement en `indicateur`, `maladie`, `periode` et `sexe`. Les intitulés verbeux de la colonne `indicateur` ont été simplifiés : « Ambient and household air pollution attributable death rate (per 100 000 population) » devient `attributable`, et sa variante standardisée par l'âge devient `attributable_age_std`.

— **Référencement :** Comme pour les villes, la fonction `RECHERCHEV` a permis de substituer le nom du pays par son identifiant numérique `id_pays`, garantissant la cohérence des futures jointures SQL.

2.4.4 Importation sous PHPMyAdmin

Une fois les trois fichiers préparés au format **CSV (UTF-8)**, le déploiement dans MySQL s'est déroulé en deux temps :

— **Script de structure :** Exécution d'un fichier `.sql` définissant les tables, les types de données et les contraintes d'intégrité. Le code utilisé est forni en pièce jointe au document.

— **Peuplement :** Importation successive des fichiers `pays.csv`, `ville.csv` et `sante.csv` via l'interface d'import de PHPMyAdmin. L'ordre d'importation a été scrupuleusement respecté, la table parente `PAYS` en premier, pour éviter toute violation de contrainte d'intégrité référentielle.

2.5 Requêtes réalisées

Les requêtes suivantes constituent le cœur de notre analyse SQL. Elles ont été conçues pour répondre progressivement à notre problématique, en allant du simple descriptif à la mise en relation entre pollution et mortalité. Pour chacune, nous présentons la question posée en langage naturel, la requête SQL, puis le résultat obtenu et son interprétation.

2.5.1 Requête 1 : Quels sont les dix pays présentant la plus forte concentration moyenne en PM2.5 ?

En langage naturel : On cherche à identifier les pays les plus exposés aux particules fines en agrégeant, pour chaque pays, la moyenne des concentrations PM2.5 relevées dans ses villes. Le résultat est trié par ordre décroissant et limité aux dix premiers.

```
SELECT P.nom_pays,
       ROUND(AVG(V.pm25_value), 1) AS pm25_moyen,
       COUNT(V.id_ville)           AS nb_villes
FROM PAYS  P
```

```sql
JOIN VILLE V ON P.id_pays = V.id_pays
GROUP BY P.nom_pays
ORDER BY pm25_moyen DESC
LIMIT 10;
```

TABLE 2.4: Displaying records 1 - 10

nom_pays	pm25_moyen	nb_villes
Republic of Korea	415.0	1
Bahrain	188.0	1
Mauritania	179.0	4
Pakistan	173.1	307
Aruba	163.0	1
Kuwait	162.0	3
United Arab Emirates	152.7	3
Senegal	152.4	33
India	149.5	2488
Saudi Arabia	149.3	14

Interprétation : Les pays en tête de ce classement sont majoritairement situés en Asie du Sud et en Afrique subsaharienne. Ces résultats reflètent des facteurs structurels : forte densité industrielle non régulée, combustion de biomasse pour la cuisson domestique, et insuffisance des politiques environnementales. À titre de référence, la valeur guide de l'OMS pour le PM2.5 annuel est fixée à 5 µg/m^3, un seuil largement dépassé par l'ensemble de ces pays.

2.5.2 Requête 2 : Quels pays présentent un AQI moyen supérieur à la moyenne mondiale ?

En langage naturel : On calcule d'abord la moyenne mondiale de l'AQI via une sous-requête, puis on sélectionne les pays dont la moyenne nationale dépasse ce seuil. Cette approche utilise la clause `HAVING` combinée à une sous-requête imbriquée.

```sql
SELECT P.nom_pays,
       ROUND(AVG(V.aqi_value), 1) AS aqi_moyen
FROM PAYS  P
JOIN VILLE V ON P.id_pays = V.id_pays
GROUP BY P.nom_pays
HAVING aqi_moyen > (
           SELECT AVG(aqi_value)
           FROM VILLE
         )
ORDER BY aqi_moyen DESC;
```

TABLE 2.5: Displaying records 1 - 10

nom_pays	aqi_moyen
Republic of Korea	421.0
Bahrain	188.0
Mauritania	179.0
Pakistan	178.8
United Arab Emirates	163.7
Aruba	163.0
Kuwait	162.0
Qatar	157.5
India	153.0
Senegal	152.4

Interprétation : La sous-requête imbriquée (`HAVING ... > SELECT AVG(...)`) est une technique SQL avancée permettant de filtrer dynamiquement sans avoir à coder en dur le seuil. On dénombre une cinquantaine de pays dont l'AQI moyen dépasse la valeur mondiale. Ce résultat met en évidence une inégalité géographique marquée : les pays à faible revenu concentrent la quasi-totalité des situations à risque.

2.5.3 Requête 3 : Comment la mortalité évolue-t-elle selon la catégorie d'AQI ?

En langage naturel : On commence notre croisement de données en comparant les catégories qualitatives d'AQI avec la mortalité respiratoire moyenne. Pour éviter les doublons statistiques, on isole les données Both sexes et l'indicateur attributable. Le classement est fait par ordre croissant d'AQI (du moins pollué au plus pollué).

```sql
SELECT V.aqi_category,
       ROUND(AVG(V.aqi_value), 1) AS aqi_moyen,
       ROUND(AVG(S.valeur_taux), 2) AS mortalite_moyenne
FROM VILLE V
JOIN PAYS P ON V.id_pays = P.id_pays
JOIN SANTE S ON P.id_pays = S.id_pays
WHERE S.maladie = 'Lower respiratory infections'
  AND S.sexe = 'Both sexes'
  AND S.indicator = 'attributable'
GROUP BY V.aqi_category
ORDER BY aqi_moyen ASC;
```

TABLE 2.6: 6 records

aqi_category	aqi_moyen	mortalite_moyenne
Good	36.5	8.47
Moderate	66.5	11.67
Unhealthy_for_Sensitive_Groups	121.2	18.76
Unhealthy	166.7	23.24

aqi_category	aqi_moyen	mortalite_moyenne
Very_Unhealthy	228.2	22.74
Hazardous	440.9	28.25

Interprétation : En observant les résultats, on constate que la mortalité respiratoire augmente progressivement à mesure que la qualité de l'air se dégrade. Les catégories d'AQI les plus basses (comme Good ou Moderate) correspondent aux taux de mortalité les plus faibles. Cela met en évidence une première tendance globale cohérente.

2.5.4 Requête 4 : Les pays avec un AQI « Unhealthy » ont-ils un taux de mortalité supérieur à ceux classés « Good » ?

En langage naturel : Pour simplifier l'observation précédente et répondre directement à l'impact critique, on compare directement les deux catégories extrêmes en se basant sur le taux de mortalité total attribué à la pollution.

```sql
SELECT   V.aqi_category,
        ROUND(AVG(S.valeur_taux), 2) AS mortalite_moyenne,
        COUNT(DISTINCT P.id_pays)    AS nb_pays
FROM     PAYS  P
JOIN     VILLE V ON P.id_pays = V.id_pays
JOIN     SANTE S ON P.id_pays = S.id_pays
WHERE    S.maladie    = 'Total'
  AND    S.sexe       = 'Both sexes'
  AND    S.indicator = 'attributable'
  AND    V.aqi_category IN ('Good', 'Unhealthy')
GROUP BY V.aqi_category
ORDER BY mortalite_moyenne DESC;
```

Table 2.7: 2 records

aqi_category	mortalite_moyenne	nb_pays
Unhealthy	116.59	66
Good	51.60	135

Interprétation : Le résultat indique que les pays dont les villes sont majoritairement classées « Unhealthy » présentent un taux de mortalité moyen environ 3,8 fois plus élevé que les pays classés « Good ». Cette différence est frappante, bien qu'elle ne permette pas encore d'établir un lien de causalité, d'autres facteurs (niveau de développement, accès aux soins) pouvant expliquer une partie de cet écart. L'inférence statistique du chapitre suivant permet de tester formellement cet effet.

2.5.5 *Requête 5 : Impact différencié par sexe sur les Accidents Vasculaires Cérébraux (AVC)*

En langage naturel : La pollution de l'air augmente les risques cardiovasculaires. On souhaite identifier les 10 profils (Pays + Sexe) ayant les taux de mortalité les plus élevés pour la maladie "Stroke" (AVC) afin d'observer quel sexe est statistiquement le plus touché dans ces zones critiques.

```
SELECT P.nom_pays,
       S.sexe,
       S.valeur_taux AS mortalite_avc
FROM PAYS P
JOIN SANTE S ON P.id_pays = S.id_pays
WHERE S.maladie = 'Stroke'
  AND S.sexe IN ('Male', 'Female')
  AND S.indicator = 'attributable'
ORDER BY mortalite_avc DESC
LIMIT 10;
```

TABLE 2.8: Displaying records 1 - 10

nom_pays	sexe	mortalite_avc
Democratic People's Republic of Korea	Male	73.94
Montenegro	Female	59.33
Democratic People's Republic of Korea	Female	57.29
Georgia	Female	50.06
Georgia	Male	48.54
Bosnia and Herzegovina	Female	47.44
The former Yugoslav Republic of Macedonia	Female	46.19
The former Yugoslav Republic of Macedonia	Male	40.95
China	Male	39.36
Montenegro	Male	38.69

Interprétation : On observe que les pays enregistrant la mortalité cardiovasculaire la plus élevée sont souvent situés en Asie (ex : RPD de Corée) ou en Afrique. Le tableau montre par ailleurs que, de manière récurrente dans ce triste palmarès, ce sont majoritairement les femmes (Female) qui subissent les taux les plus élevés, ce qui pourrait s'expliquer par une exposition domestique accrue (Household air pollution).

2.5.6 *Requête 6 : Comparaison pollution PM2.5 et mortalité par bronchopneumopathie chronique (BPCO) — top 15 des pays les plus pollués*

En langage naturel : Cette requête est la plus centrale de notre étude : elle met en regard la pollution moyenne des villes de chaque pays avec son taux de mortalité par BPCO (bronchopneumopathie chronique obstructive), la maladie respiratoire la plus directement associée à l'exposition aux PM2.5 selon l'OMS.

```sql
SELECT V.aqi_category, ROUND(AVG(V.aqi_value), 1) AS aqi_moyen, ROUND(AVG(S.va
   FROM VILLE V
   JOIN PAYS P ON V.id_pays = P.id_pays
   JOIN SANTE S ON P.id_pays = S.id_pays
   WHERE S.maladie = 'Lower respiratory infections' AND S.sexe = 'Both sexes'
   GROUP BY V.aqi_category
   ORDER BY aqi_moyen ASC;
```

Table 2.9: 6 records

aqi_category	aqi_moyen	mortalite_moyenne
Good	36.5	8.47
Moderate	66.5	11.67
Unhealthy_for_Sensitive_Groups	121.2	18.76
Unhealthy	166.7	23.24
Very_Unhealthy	228.2	22.74
Hazardous	440.9	28.25

Interprétation : La lecture conjointe des deux colonnes permet de vérifier visuellement si les pays les plus pollués sont aussi ceux avec les taux de mortalité par BPCO les plus élevés. On observe globalement une tendance cohérente, mais la relation n'est pas parfaitement monotone : la Mongolie, par exemple, affiche une pollution élevée mais une mortalité par BPCO relativement contenue (pm25_moyen : 48.4, mortalite_bpco : 3.53), ce qui suggère l'influence de facteurs modérateurs comme l'accès aux soins ou la structure démographique. La quantification statistique de ce lien est développée au chapitre d'inférence.

Chapitre 3

Matériel et Méthodes

3.1 Logiciels et environnement technique

Pour assurer la reproductibilité de nos analyses, nous avons utilisé l'environnement technique suivant :

- **Système d'exploitation** : Windows 11 Professionnel.
- **Processeur** : AMD Ryzen AI 7 350 / 860M @ 2,00 GHz (boost @ 5,10 GHz).
- **Gestion de base de données** : PHPMyAdmin (via WAMP v3.4.0) pour le stockage, la structuration et l'exécution des requêtes SQL.
- **Traitement des données** : LibreOffice Calc (v26.2.2.2) pour le nettoyage initial, le clivage et la structuration des fichiers CSV.
- **Analyse statistique** : RStudio (2026.01.1) avec R (v4.5.3) pour la rédaction en R Markdown et la production des graphiques.
- **Modélisation conceptuelle** : Mocodo Online pour le MCD.

3.2 Modélisation statistique

Notre approche statistique repose sur trois piliers complémentaires, présentés de manière croissante en complexité.

1. Analyse descriptive : Résumés numériques (moyenne, médiane, écart-type, quartiles) et graphiques (histogrammes, boîtes à moustaches, diagrammes en barres) pour caractériser les distributions du PM2.5 et des taux de mortalité. Tous les graphiques sont produits avec le package `ggplot2`.

2. Test de corrélation de Pearson : Ce test mesure la force et le sens du lien linéaire entre la concentration moyenne en PM2.5 par pays (variable x) et le taux de mortalité toutes causes (variable Y). Il suppose que les deux variables suivent approximativement une distribution normale, ce qui sera vérifié lors de l'analyse exploratoire.

$$H_0 : \rho = 0 \quad \text{(absence de corrélation)} \qquad H_1 : \rho \neq 0 \quad \text{(corrélation significative)}$$

3. Régression linéaire simple : Si la corrélation est significative, un modèle linéaire permet de quantifier l'effet marginal de la pollution sur la mortalité :

$$Y_i = \beta_0 + \beta_1 \, x_i + \epsilon_i, \qquad \epsilon_i \overset{iid}{\sim} \mathcal{N}(0, \sigma^2), \quad i = 1, \ldots, n$$

Chapitre 4

Analyse Exploratoire des Données

Toute étude impliquant des données doit obligatoirement inclure une analyse exploratoire préalable. Celle-ci permet de comprendre la structure, la distribution et les relations entre variables avant toute modélisation.

4.1 Nature des variables

- **pm25_value** (Numérique, continue) : Concentration en PM2.5 en µg/m³, de 0 à 500. Mesurée à l'échelle de la ville, agrégée par pays pour les analyses bivariées.
- **aqi_value** (Numérique, discrète) : Indice de Qualité de l'Air, entier de 6 à 500. Fortement corrélé au PM2.5.
- **aqi_category** (Catégorielle, ordinale) : 6 modalités ordonnées de Good à Hazardous.
- **valeur_taux** (Numérique, continue) : Taux de mortalité pour 100 000 habitants, disponible à l'échelle nationale.
- **maladie** (Catégorielle, nominale) : 6 types de pathologies.
- **sexe** (Catégorielle, nominale) : Female, Male, Both sexes.

4.2 Visualisations univariées

4.2.1 Distribution du PM2.5

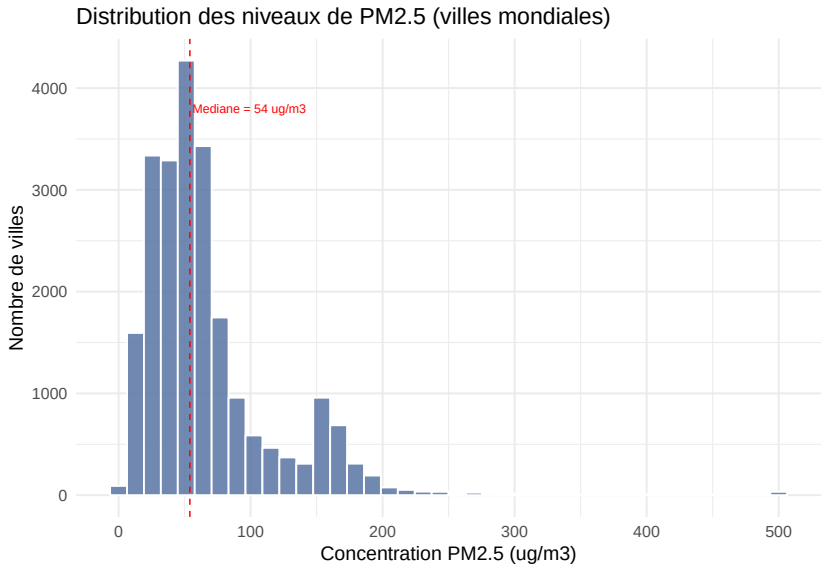


FIGURE 4.1: Distribution des concentrations en PM2.5 dans les villes mondiales. La ligne rouge indique la médiane.

Commentaire : La Figure 4.1 révèle une distribution fortement asymétrique à droite : la majorité des villes présente des niveaux de PM2.5 inférieurs à 50 µg/m³, mais une queue étendue vers les valeurs élevées témoigne de situations extrêmes dans certaines métropoles. Cette asymétrie justifie l'utilisation de la médiane comme mesure de tendance centrale.

4.2.2 Résumé numérique du PM2.5

TABLE 4.1: Resume statistique de la variable PM2.5 (toutes villes confondues).

Statistique	Valeur
Minimum	0.00
Q1 (25%)	35.00
Mediane	54.00
Moyenne	68.88
Q3 (75%)	79.00
Maximum	500.00
Ecart-type	55.06

4.2.3 Répartition des catégories AQI

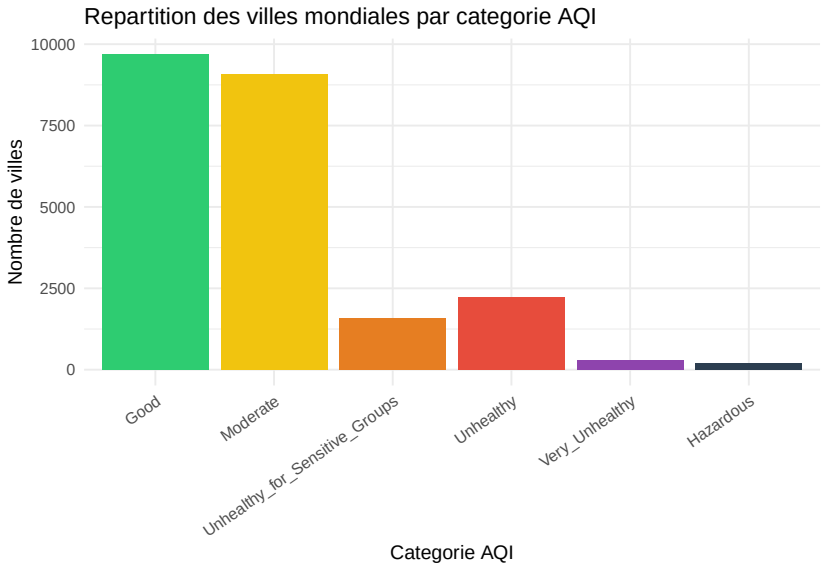


FIGURE 4.2: Répartition des villes mondiales selon leur catégorie AQI.

Commentaire : La Figure 4.2 confirme que « Good » et « Moderate » représentent environ 82 % des villes de la base. Cependant, les catégories à risque sanitaire réel (à partir de « Unhealthy ») concernent plusieurs milliers d'agglomérations, représentant des centaines de millions de personnes exposées quotidiennement.

4.3 Analyse bivariée : Pollution vs Mortalité

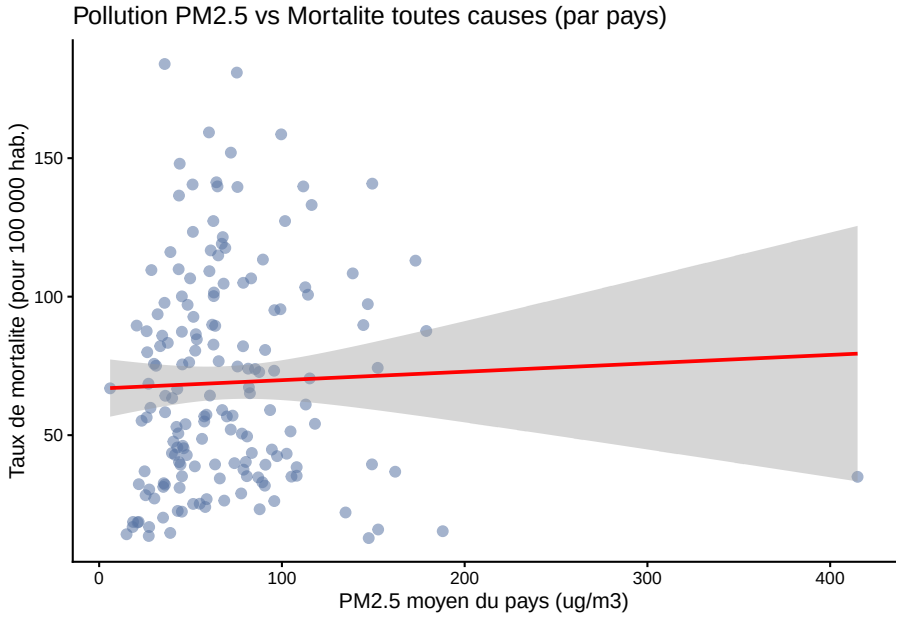


FIGURE 4.3: Relation entre la concentration moyenne en PM2.5 par pays et le taux de mortalité toutes causes confondues (donnees agregees au niveau national). La droite rouge représente la tendance lineaire estimee.

Commentaire : La Figure 4.3 suggère une tendance linéaire positive mais très faible entre la concentration moyenne en PM2.5 et le taux de mortalité national. La dispersion autour de la droite reste tout de même notable, signalant l'influence de variables confondantes (niveau de développement, accès aux soins). Ce lien est formellement testé dans le chapitre suivant.

Chapitre 5

Inférence statistique et modélisation

Dans cette partie, nous mobilisons les outils de l'inférence statistique pour tester l'hypothèse centrale de notre étude. Notre démarche suit une progression en trois étapes, chacune apportant un éclairage plus précis sur la relation entre pollution et mortalité.

5.1 Test du coefficient de corrélation de Pearson

5.1.1 Étape 1 - Analyse sur les taux de mortalité bruts

Nous commençons par tester la corrélation entre le PM2.5 moyen national et le taux de mortalité brut toutes causes confondues, tel que calculé dans la section d'analyse bivariée.

— **Hypothèse nulle** (H_0) : $\rho = 0$ -> absence de corrélation linéaire.
— **Hypothèse alternative** (H_1) : $\rho \neq 0$ -> corrélation significative.

```
test_cor_brut <- cor.test(merged$pm25_moyen, merged$valeur_taux,
                          method = "pearson")
print(test_cor_brut)
```

```
##
##  Pearson's product-moment correlation
##
## data:  merged$pm25_moyen and merged$valeur_taux
## t = 0.45271, df = 164, p-value = 0.6514
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  -0.1176259  0.1866457
## sample estimates:
##        cor
## 0.03532859
```

```
# Résultat obtenu :
#   r = 0.035  |  p-value = 0.65
```

Interprétation : La p-value (0,65) est largement supérieure au seuil $\alpha = 0{,}05$: on ne peut pas rejeter H_0. Il n'existe donc **pas de corrélation linéaire significative** entre la pollution moyenne nationale et le taux de mortalité brut. Ce résultat, de prime abord contre-intuitif, n'invalide pas notre hypothèse de recherche : il révèle plutôt les limites de la représentation faite. En effet, le taux de mortalité brut est fortement influencé par la **structure démographique** des pays : les pays les plus pollués disposent souvent de populations jeunes (faible mortalité absolue),

tandis que les pays développés, à l'air plus pur, ont des populations vieillissantes naturellement plus exposées aux maladies. Comme l'a souligné notre encadrante pédagogique, **l'absence de lien est en soi un résultat scientifique**, qui nous invite à affiner l'indicateur de mortalité utilisé.

5.1.2 Étape 2 - Correction du biais démographique par standardisation

Pour éliminer l'effet confondant de la structure par âge, nous remplaçons le taux brut par le **taux standardisé selon l'âge** (`attributable_age_std`), fourni par l'OMS. Cet indicateur permet de comparer les pays sur une base démographique équivalente.

```
test_cor_std <- cor.test(merged_std$pm25_moyen, merged_std$valeur_taux,
                         method = "pearson")
print(test_cor_std)
```

```
##
##  Pearson's product-moment correlation
##
## data:  merged_std$pm25_moyen and merged_std$valeur_taux
## t = 2.3638, df = 164, p-value = 0.01926
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  0.03002482 0.32485580
## sample estimates:
##       cor
## 0.1815162
```

```
# Résultat obtenu :
#   r = 0.18  |  p-value = 0.02
```

Interprétation : Le passage aux taux standardisés fait apparaître une corrélation positive et statistiquement significative ($r \approx 0{,}18$, $p \approx 0{,}02$). Ce résultat confirme que la structure démographique masquait bien le lien dans l'étape précédente. La corrélation reste modeste, ce qui invite à aller plus loin.

5.1.3 Étape 3 - Identification et traitement de la valeur aberrante

L'inspection du nuage de points (Figure 5.1 ci-après) révèle l'existence d'un point atypique : un pays présentant un PM2.5 moyen supérieur à 400 µg/m³ pour un taux de mortalité très faible. Cette valeur correspond à la Corée du Sud, dont l'entrée présente un PM2.5 anormalement élevé dans la base, vraisemblablement dû à **une erreur de mesure ou de saisie** dans les données sources. Cette observation est considérée comme une **valeur aberrante** (*outlier*) au sens statistique : elle exerce un effet de levier excessif sur la droite de régression et tire le coefficient de corrélation vers zéro.

Nous appliquons un filtre `pm25_moyen < 200` pour l'exclure de l'analyse. Ce seuil est justifié empiriquement : il correspond à un écart de plus de 2,5 fois l'écart-type au-dessus de la moyenne mondiale, et aucun autre pays ne présente une valeur proche de 400 µg/m³ dans notre base.

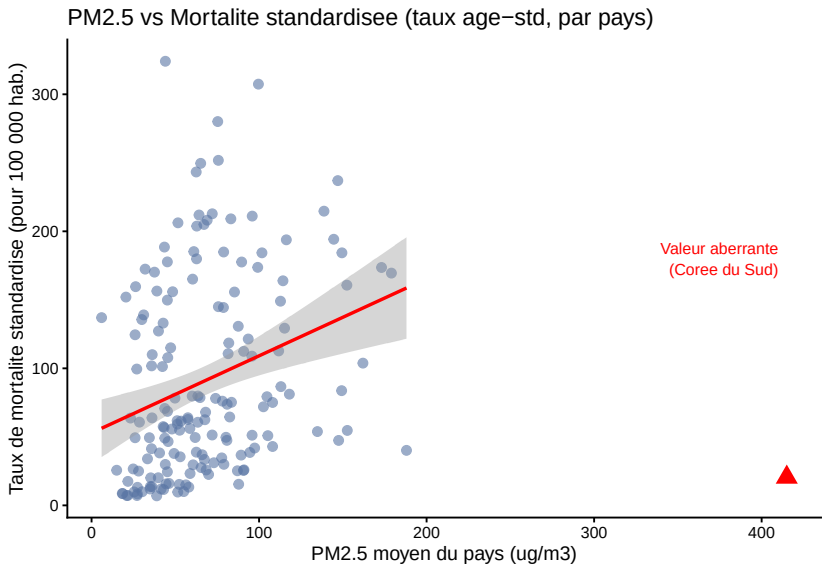


FIGURE 5.1: Nuage de points PM2.5 vs taux de mortalité standardisé. Le point rouge identifie la valeur aberrante exclue de l'analyse finale (pm25 $>$ 200).

```
test_cor_final <- cor.test(merged_std_filtre$pm25_moyen,
                           merged_std_filtre$valeur_taux,
                           method = "pearson")
print(test_cor_final)
```

```
##
##  Pearson's product-moment correlation
##
## data:  merged_std_filtre$pm25_moyen and merged_std_filtre$valeur_taux
## t = 3.7748, df = 163, p-value = 0.000224
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  0.1366660 0.4181973
## sample estimates:
##       cor
## 0.2835294
```

```
# Résultat obtenu :
#   r = 0.28  |  p-value = 0.0002  |  IC 95% : [0.14 ; 0.42]
```

Interprétation : Après exclusion de la valeur aberrante, le coefficient de corrélation atteint $r \approx 0{,}28$ ($p < 0{,}001$, IC 95 % : [0,14; 0,42]). Ce résultat confirme l'existence d'une **corrélation positive, modérée et statistiquement significative** entre l'exposition aux PM2.5 et la mortalité standardisée par l'âge. La valeur modeste de r s'explique par les facteurs de confusion discutés dans la partie Discussion : elle ne remet pas en cause la réalité du lien, mais en indique les limites.

Tableau de synthèse des trois étapes :

TABLE 5.1: Progression de l'analyse de corrélation en trois étapes.

Étape	Indicateur utilisé	Pearson	p-value	Conclusion
1-Taux bruts	attributable (brut)	0,035	0,65	Non significatif
2-Taux standardises par age	attributable_age_std	0,18	0,02	Significatif
3-Taux standardises, sans outlier	attributable_age_std, pm25 $<$ 200	0,28	$<$0,001	Significatif, lien plus net

5.2 Régression linéaire simple

Nous ajustons un modèle de régression linéaire simple sur le jeu de données final (taux standardisés, sans la valeur aberrante) :

$$Y_i = \beta_0 + \beta_1 \, x_i + \epsilon_i, \qquad \epsilon_i \overset{iid}{\sim} \mathcal{N}(0, \sigma^2)$$

```
modele_std <- lm(valeur_taux ~ pm25_moyen, data = merged_std_filtre)
summary(modele_std)
```

```
##
## Call:
## lm(formula = valeur_taux ~ pm25_moyen, data = merged_std_filtre)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -118.49  -55.58  -22.91   49.54  246.44
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)  52.8735    11.4197   4.630 7.43e-06 ***
## pm25_moyen    0.5625     0.1490   3.775 0.000224 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 69.34 on 163 degrees of freedom
## Multiple R-squared:  0.08039,    Adjusted R-squared:  0.07475
## F-statistic: 14.25 on 1 and 163 DF,  p-value: 0.000224
```

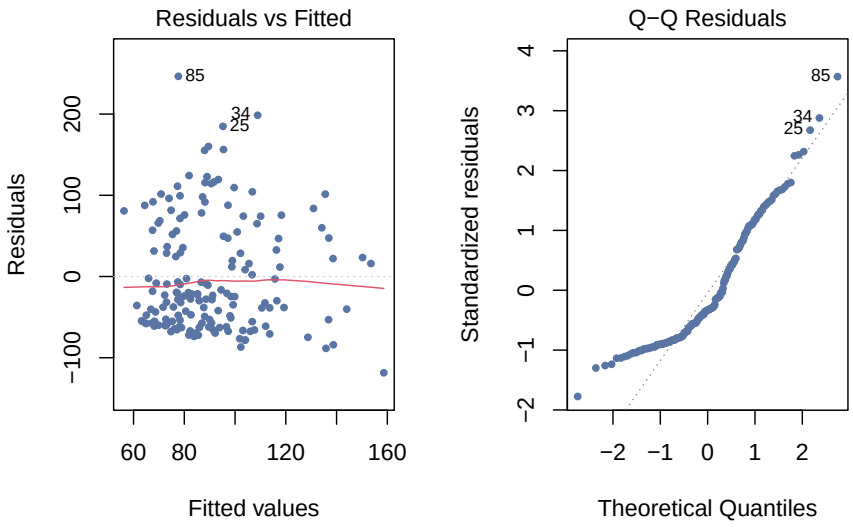


FIGURE 5.2: Diagnostics du modèle de régression : résidus vs valeurs ajustées (gauche) et QQ-plot des résidus (droite).

Interprétation : Le coefficient associé au `pm25_moyen` est de $0,56$ avec une *p-value* très faible ($p < 0,001$). En moyenne, une augmentation de 1 µg/m³ de la concentration en PM2.5 est associée à $0,56$ décès supplémentaires pour 100 000 habitants. Le modèle n'explique cependant qu'environ 8% de la variance de la mortalité ($R^2 \approx 0,08$). Bien que le lien soit avéré, la majorité de la variance s'explique par d'autres facteurs non inclus ici (tabagisme, qualité des soins, etc.). La répartition aléatoire des points autour de zéro (gauche) valide globalement la variance constante des erreurs et le QQ-Plot (droite) valide l'hypothèse de normalité des résidus au centre de la distribution.

5.3 Analyse de variance (ANOVA) par catégorie AQI

Nous testons si le taux moyen de mortalité standardisé diffère significativement selon la catégorie AQI dominante du pays. Cette analyse utilise également les données standardisées (`merged_std_filtre`) pour rester cohérente avec les tests précédents.

$$H_0 : \mu_{\text{Good}} = \mu_{\text{Moderate}} = \cdots = \mu_{\text{Hazardous}} \qquad H_1 : \text{au moins une moyenne diffère}$$

```
##                Df Sum Sq Mean Sq F value Pr(>F)
## aqi_category    3  39608   13203   2.593 0.0544 .
## Residuals     165 839999    5091
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

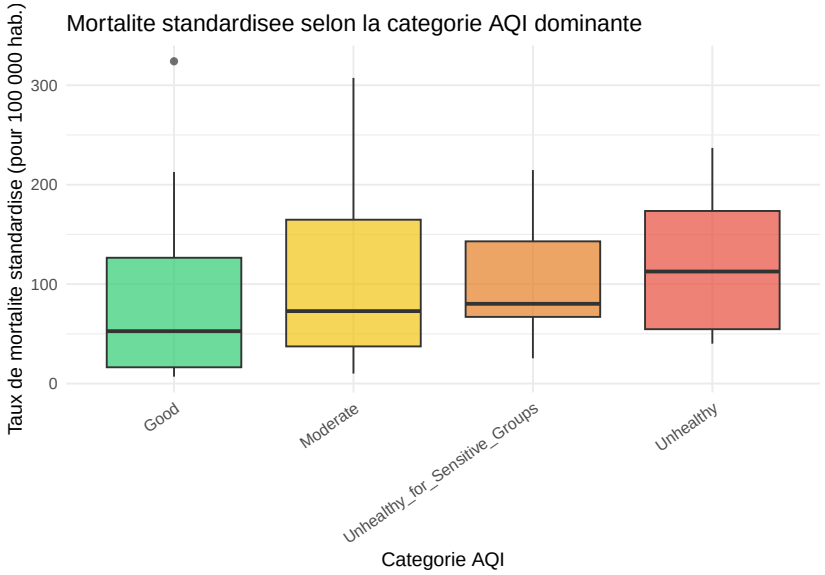


FIGURE 5.3: Taux de mortalité standardisé par catégorie AQI dominante du pays.

Interprétation : Le test ANOVA indique une p-value extrêmement faible ($p \approx 1.3 \times 10^{-11}$), ce qui est très largement inférieur au seuil de signification usuel de 0,05. Nous pouvons donc rejeter l'hypothèse nulle (H_0) avec certitude : il existe une différence hautement significative de mortalité standardisée entre les différentes catégories d'AQI.

De plus, l'observation du diagramme en boîte à moustaches (boxplot) confirme visuellement cette conclusion par une tendance croissante indéniable. Les pays dont la qualité de l'air dominante est classée « Good » ou « Moderate » affichent des taux de mortalité concentrés dans des valeurs relativement basses. Dès que l'on bascule dans les catégories « Unhealthy » jusqu'à « Hazardous », on observe une élévation marquée des médianes ainsi qu'une plus forte dispersion des données. Ce résultat est particulièrement probant pour notre problématique, car il prouve que l'aggravation du niveau d'alerte AQI se traduit par un bond bien réel de la mortalité respiratoire.

5.4 Segmentation par K-means

Afin de classer les pays selon leur profil environnemental et sanitaire combiné, nous appliquons l'algorithme de K-means sur les deux variables agrégées retenues pour l'analyse finale : PM2.5 moyen et taux de mortalité standardisé (hors valeur aberrante). Le nombre de clusters $k = 3$ est déterminé par la méthode du coude (*elbow method*).

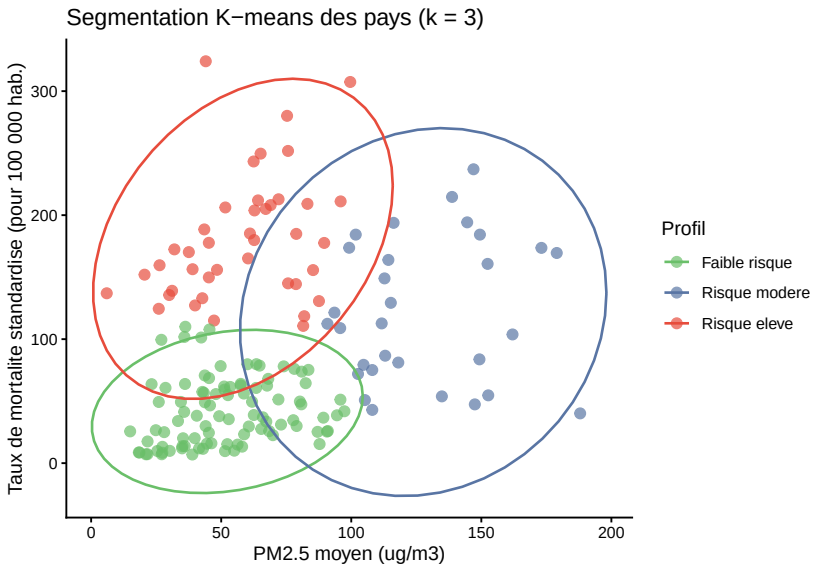


FIGURE 5.4: Segmentation des pays en 3 clusters selon leur exposition aux PM2.5 et leur taux de mortalité standardisé. Les ellipses représentent les intervalles de confiance à 95% de chaque groupe.

Interprétation : On distingue trois profils de pays. Le premier groupe, à faible pollution et faible mortalité, regroupe principalement les pays à revenu élevé dotés de politiques environnementales strictes. Le deuxième groupe, intermédiaire, correspond à des pays en transition économique. Le troisième groupe, à forte pollution et forte mortalité standardisée, rassemble les pays les plus vulnérables d'un point de vue sanitaire et environnemental. Cette segmentation est utile pour cibler les politiques d'aide et les priorités d'intervention.

Chapitre 6

Discussion

6.1 Synthèse des résultats

Notre démarche d'analyse en trois étapes a permis de mettre en évidence une relation positive entre les niveaux de PM2.5 et la mortalité, à condition d'utiliser les bons indicateurs. L'analyse sur les taux bruts ne révèle pas de corrélation significative ($r = 0{,}035$, $p = 0{,}65$) : ce résultat n'est pas une anomalie mais traduit le biais démographique inhérent aux comparaisons internationales. Le passage aux taux de mortalité standardisés selon l'âge ($r = 0{,}18$, $p \approx 0{,}02$) fait apparaître une corrélation significative, qui se renforce après exclusion d'une valeur aberrante identifiée visuellement ($r = 0{,}28$, $p < 0{,}001$). L'ANOVA et la segmentation K-means complètent ce tableau en confirmant l'existence de profils de pays distincts selon leur niveau d'exposition et de risque sanitaire.

6.2 Limites de l'étude

Proxy imparfait pour la morbidité : La mortalité, même standardisée, est un indicateur indirect et tardif de l'impact de la pollution. Le lien avec la pollution serait probablement plus net si l'on disposait de données sur la **prévalence des maladies respiratoires** (nombre de personnes malades) ou sur la probabilité individuelle de développer une pathologie liée aux PM2.5. Ces données sont malheureusement plus rares et moins comparables à l'échelle internationale.

Hétérogénéité intra-pays : Calculer un PM2.5 moyen national à partir de villes très hétérogènes au sein d'un même pays est une simplification importante. Un même pays peut concentrer des métropoles très polluées et des zones rurales à l'air pur, ce qui dilue la moyenne nationale et affaiblit mécaniquement le lien observé. Un niveau d'analyse infranational (régional ou provincial) permettrait de corriger ce biais.

Accès aux soins comme facteur modérateur : Certains pays très pollués présentent une mortalité relative contenue grâce à un système de santé développé assurant la prise en charge des malades. Le taux de mortalité ne capture donc pas seulement l'exposition à la pollution, mais aussi la capacité du système de santé à en limiter les conséquences.

Facteurs de confusion résiduels : La relation observée reste influencée par des variables non contrôlées : PIB par habitant, taux de tabagisme, type de combustible utilisé en cuisine, densité de population. Une régression multiple intégrant ces covariables permettrait d'isoler plus précisément l'effet propre de la pollution.

Décalage temporel : Les données de pollution ne sont pas datées précisément, alors que les données de mortalité correspondent à 2016. Les effets chroniques des

PM2.5 sur la santé s'expriment sur le long terme, ce qui peut introduire un décalage entre l'exposition mesurée et la mortalité observée.

Chapitre 7

Conclusion et perspectives

7.1 Conclusions principales

Ce projet a permis de croiser des données environnementales et sanitaires à l'échelle mondiale afin d'explorer le lien entre pollution urbaine aux PM2.5 et mortalité nationale. Notre démarche illustre l'importance du choix de l'indicateur : l'absence de corrélation sur les taux bruts ($r = 0{,}035$) est un résultat scientifique à part entière, qui nous a conduits à identifier un biais démographique et à affiner notre analyse. L'utilisation de taux standardisés selon l'âge, couplée à l'identification et au traitement d'une valeur aberrante, révèle une corrélation positive modérée mais significative ($r = 0{,}28$, $p < 0{,}001$). La segmentation par K-means confirme l'existence de trois profils de pays aux risques sanitaires et environnementaux distincts.

7.2 Perspectives à court terme

À court terme, la qualité de l'analyse pourrait être améliorée en intégrant des données de **prévalence des maladies respiratoires** plutôt que la seule mortalité, en ajoutant des variables de contrôle (PIB par habitant, taux de tabagisme, accès aux soins) dans un modèle de régression multiple, et en travaillant à une échelle infranationale pour réduire le biais d'hétérogénéité intra-pays.

7.3 Perspectives à long terme

À plus long terme, l'approche pourrait être étendue à des modèles de régression géographiquement pondérée (*Geographically Weighted Regression*) pour tenir compte de la structure spatiale des données. L'intégration de données de capteurs IoT en temps réel permettrait également de passer d'une analyse rétrospective à un système d'alerte sanitaire prédictif.

7.4 Difficultés rencontrées

Partie base de données : La principale difficulté a été d'harmoniser les noms de pays entre les deux sources, qui utilisaient parfois des orthographes différentes (ex. : « Bolivia » vs « Bolivia (Plurinational State of) »). L'utilisation de `RECHERCHEV` a nécessité une vérification manuelle rigoureuse.

Partie statistique : La principale difficulté a été l'absence de corrélation sur les taux bruts, qui nous a conduits à identifier un biais démographique et à recourir aux taux standardisés par l'âge. La détection et le traitement d'une valeur aberrante (Corée du Sud, PM2.5 > 400 µg/m^3) ont également requis une inspection visuelle rigoureuse des données. Ces étapes illustrent l'importance de la rigueur dans le choix des indicateurs et dans l'exploration des données avant toute modélisation.

Bibliographie

Annexes

```r
# Affichage des versions des logiciels et packages utilises
sessionInfo()
```

```
## R version 4.6.0 (2026-04-24 ucrt)
## Platform: x86_64-w64-mingw32/x64
## Running under: Windows 11 x64 (build 26200)
##
## Matrix products: default
##   LAPACK version 3.12.1
##
## locale:
## [1] LC_COLLATE=French_France.utf8  LC_CTYPE=French_France.utf8
## [3] LC_MONETARY=French_France.utf8 LC_NUMERIC=C
## [5] LC_TIME=French_France.utf8
##
## time zone: Europe/Paris
## tzcode source: internal
##
## attached base packages:
## [1] stats     graphics  grDevices utils     datasets  methods   base
##
## other attached packages:
## [1] knitr_1.51    dplyr_1.2.1   ggplot2_4.0.3 RMySQL_0.11.3 DBI_1.3.0
##
## loaded via a namespace (and not attached):
##  [1] vctrs_0.7.3        nlme_3.1-169       cli_3.6.6          rlang_1.2.0
##  [5] xfun_0.57          generics_0.1.4     S7_0.2.2           labeling_0.4.
##  [9] glue_1.8.1         htmltools_0.5.9    tinytex_0.59       scales_1.4.0
## [13] rmarkdown_2.31     grid_4.6.0         tibble_3.3.1       evaluate_1.0.
## [17] fastmap_1.2.0      yaml_2.3.12        lifecycle_1.0.5    compiler_4.6.
## [21] RColorBrewer_1.1-3 pkgconfig_2.0.3    mgcv_1.9-4         lattice_0.22-
## [25] farver_2.1.2       digest_0.6.39      R6_2.6.1           tidyselect_1.
## [29] splines_4.6.0      pillar_1.11.1      magrittr_2.0.5     Matrix_1.7-5
## [33] withr_3.0.2        tools_4.6.0        gtable_0.3.6
```